

autumnqp 님의 블로그

Search...

메뉴바를 클릭하면  
계정을 관리할 수 있어요

카테고리 없음

# [ Paper Review ] Deep Contextualized Word

autumnqp 2026. 4. 29. 21:14

## 논문 링크

Peters, M. E., Neumann, M., Iyyer, M., Gardner, M., Clark, C., Lee, K., & Zettlemoyer, L. (2018). Deep Contextualized Word Representations. NAACL 2018. <https://arxiv.org/abs/1802.05365>

# 1. Introduction — 왜 이 논문이 나왔는가?

Word2Vec, GloVe와 같은 기존 단어 임베딩은 NLP 모델의 핵심 구성 요소였지만, 치명적인 한계가 있었습니다. 바로 **각 단어에 단 하나의 고정된 벡터**를 할당한다는 점입니다.

예를 들어 "bank"라는 단어는 "강둑"과 "은행" 두 가지 의미를 가지지만, 기존 임베딩은 어떤 문장에서 쓰이든 항상 동일한 벡터를 반환합니다. 문맥에 따라 의미가 달라지는 **다의어 (polysemy)**를 전혀 모델링하지 못하는 것이죠.

이 논문은 그 한계를 해결하기 위해 **ELMo(Embeddings from Language Models)**를 제안합니다. ELMo는 대규모 코퍼스에서 사전 학습된 양방향 언어 모델(biLM)의 **모든 내부 레이어**를 **선형 결합**하여 문맥에 따라 다른 단어 표현을 생성합니다.

## 2. Background — 기존 접근법의 한계

기존의 맥락화 임베딩 시도들도 있었습니다.

- **CoVe** (McCann et al., 2017): 기계 번역 인코더를 활용해 맥락화 표현을 생성했지만, 병렬 코퍼스 크기에 제한되고 최상위 레이어만 사용했습니다.
- **Peters et al. (2017)**: biLM의 최상위 레이어만을 사용하는 방식을 제안했지만, 모든 레이어를 활용하지 않아 정보 손실이 있었습니다.

ELMo의 핵심 차별점은 **"deep"**이라는 단어에 있습니다. 최상위 레이어 하나만 쓰는 것이 아니라 **모든 레이어의 표현을 태스크별로 가중합**하여 사용합니다.

## 3. Proposed Model — ELMo

### 3.1 Bidirectional Language Model (biLM)

biLM은 순방향(forward)과 역방향(backward) 두 개의 언어 모델로 구성됩니다.

**순방향 LM**: 이전 토큰들을 보고 현재 토큰을 예측합니다.

$$p(t_1, t_2, \dots, t_N) = \prod_{k=1}^N p(t_k | t_1, t_2, \dots, t_{k-1})$$

**역방향 LM:** 이후 토큰들을 보고 현재 토큰을 예측합니다.

$$p(t_1, t_2, \dots, t_N) = \prod_{k=1}^N p(t_k | t_{k+1}, t_{k+2}, \dots, t_N)$$

**biLM 학습 목표:** 두 방향의 log likelihood를 동시에 최대화합니다.

$$\sum_{k=1}^N \left( \log p(t_k | t_1, \dots, t_{k-1}; \Theta_x, \vec{\Theta}_{LSTM}, \Theta_s) + \log p(t_k | t_{k+1}, \dots, t_N; \Theta_x, \overleftarrow{\Theta}_{LSTM}) \right)$$

토큰 표현 파라미터  $\Theta_x$ 와 소프트맥스 파라미터  $\Theta_s$ 는 양방향에 공유하지만, LSTM 파라미터는 각 방향마다 독립적으로 유지됩니다.

**사전 학습 biLM 구조:** L=2 biLSTM 레이어, 레이어당 4,096 유닛과 512차원 프로젝션, 레이어 간 잔차 연결(residual connection) 사용. 토큰 표현은 **문자 단위 CNN(character n-gram convolutional filters 2,048개)** 으로 생성하므로 OOV 단어도 처리 가능합니다. 1B Word Benchmark로 10 에포크 학습, perplexity 39.7 달성.

## 3.2 ELMo Representation

L-layer biLM은 각 토큰  $t_k$ 에 대해  $2L + 1$ 개의 표현 집합  $R_k$ 를 생성합니다.

$$R_k = x^{LM} k, \vec{h}^{LM} k, j, \overleftarrow{h}^{LM} k, j \mid j = 1, \dots, L, h^{LM} k, j \mid j = 0, \dots, L$$

여기서  $h^{LM} k, 0$ 은 문자 CNN으로 만든 토큰 레이어,  $h^{LM} k, j = [\vec{h}^{LM} k, j; \overleftarrow{h}^{LM} k, j]$ 는 각 biLSTM 레이어의 연결(concatenate) 표현입니다.

최종 ELMo 벡터는 이 모든 레이어 표현의 **태스크별 가중합**입니다.

$$ELMo^{task} k = \gamma^{task} \sum_{j=0}^L s_j^{task} h^{LM} k, j$$

- $s_j^{task}$ : 소프트맥스 정규화된 레이어별 가중치 (다운스트림 태스크에서 학습)
- $\gamma^{task}$ : 전체 ELMo 벡터의 스케일을 조절하는 스칼라 파라미터

기존 연구들이 최상위 레이어( $h_{k,L}^{LM}$ )만을 사용한 것과 달리, ELMo는 모든 레이어를 태스크에 맞게 조합합니다.

### 3.3 다운스트림 태스크에 통합하는 방법

biLM의 가중치를 **고정(freeze)** 한 채로 각 단어의 모든 레이어 표현을 계산한 뒤, 기존 모델에 다음과 같이 추가합니다.

가장 기본적인 방식은 기존 토큰 표현  $x_k$ 에 ELMo 벡터를 이어붙여 태스크 RNN으로 입력하는 것입니다.

$$[x_k; ELMo_k^{task}] \rightarrow \text{Task RNN}$$

일부 태스크(SQuAD, SNLI)에서는 Task RNN의 출력에도 ELMo를 추가하면 성능이 더 향상됩니다. 또한 ELMo에 드롭아웃(dropout)을 적용하고 레이어 가중치에 L2 정규화를 추가하는 것이 효과적입니다.

## 4. Experiment Settings

- 사전 학습 데이터: 1B Word Benchmark (약 3,000만 문장)
- biLM 구조: L=2 biLSTM 레이어, 4,096 유닛, 512차원 프로젝트
- 평가 태스크: 6가지 NLP 벤치마크
  - SQuAD (Question Answering)
  - SNLI (Textual Entailment)
  - SRL (Semantic Role Labeling) — OntoNotes
  - Coref (Coreference Resolution) — CoNLL 2012
  - NER (Named Entity Recognition) — CoNLL 2003
  - SST-5 (Sentiment Analysis) — Stanford Sentiment Treebank
- 비교 대상: 각 태스크의 기존 SOTA 모델 + CoVe

## 5. Results

### 5.1 Quantitative Results — 6개 태스크 전체 SOTA 갱신

태스크기존 SOTABaselineELMo+Baseline향상 (절대/상대)

|             |       |       |       |              |
|-------------|-------|-------|-------|--------------|
| SQuAD (F1)  | 84.4  | 81.1  | 85.8  | +4.7 / 24.9% |
| SNLI (정확도)  | 88.6  | 88.0  | 88.7  | +0.7 / 5.8%  |
| SRL (F1)    | 81.7  | 81.4  | 84.6  | +3.2 / 17.2% |
| Coref (F1)  | 67.2  | 67.2  | 70.4  | +3.2 / 9.8%  |
| NER (F1)    | 91.93 | 90.15 | 92.22 | +2.06 / 21%  |
| SST-5 (정확도) | 53.7  | 51.4  | 54.7  | +3.3 / 6.8%  |

6개 태스크 전부에서 새로운 SOTA를 달성했으며, 상대적 오차 감소율이 6~25%에 달합니다. 특히 SQuAD에서는 CoVe 추가 시 1.8% 향상에 그쳤던 것이 ELMo로는 4.7% 향상되어, ELMo가 CoVe보다 훨씬 풍부한 표현을 제공함을 보여줍니다.

### 5.2 모든 레이어 사용 vs. 최상위 레이어만 사용

태스크BaselineLast OnlyAll layers ( $\lambda=1$ )All layers ( $\lambda=0.001$ )

|       |      |      |      |      |
|-------|------|------|------|------|
| SQuAD | 80.8 | 84.7 | 85.0 | 85.2 |
| SNLI  | 88.1 | 89.1 | 89.3 | 89.5 |
| SRL   | 81.6 | 84.1 | 84.6 | 84.8 |

모든 레이어를 사용할수록, 그리고 레이어별 가중치를 학습할수록 성능이 올라가는 경향이 일관되게 나타납니다.

### 5.3 ELMo를 어디에 추가할까?



태스크마다 최적 위치가 다릅니다. SQuAD와 SNLI는 입력과 출력 양쪽에 모두 넣을 때 성능이 가장 좋고, SRL은 입력에만 넣는 것이 최적이었습니다. 이는 태스크 구조에 따라 biLM 정보가 필요한 지점이 다를 수 있음을 시사합니다.

### 5.4 레이어별 인코딩 정보 분석

biLM의 레이어는 서로 다른 언어 정보를 담고 있습니다.

**하위 레이어 (1st layer):** 구문(syntax) 정보에 특화됩니다. POS Tagging에서 더 높은 정확도를 보입니다.

**상위 레이어 (2nd layer):** 의미(semantics) 정보에 특화됩니다. WSD(단어 의미 구분) 태스크에서 WordNet 1st Sense 기준선(65.9)을 상회하는 69.0 F1을 기록합니다.

GloVe의 "play" 최근접 이웃은 playing, game, games 등 단어 형태가 유사한 것들인 반면, biLM은 "play"가 사용된 문장의 문맥(스포츠 경기 / 연극)에 따라 완전히 다른 이웃을 찾아냅니다. 모든 레이어를 함께 사용하면 구문과 의미 정보를 동시에 활용할 수 있어 다양한 태스크에서 최적의 성능을 냅니다.

## 5.5 Sample Efficiency

ELMo의 또 다른 강점은 학습 데이터가 적을 때도 강력하게 작동한다는 점입니다. 데이터가 전체의 0.1%밖에 없어도 SNLI에서 +12.3%, SRL에서 +18.6의 향상을 보이며, 데이터가 늘어날수록 격차는 줄지만 100%에서도 여전히 ELMo가 우위를 유지합니다.

## 6. 결론 및 의의

이 논문은 세 가지 측면에서 NLP 역사에 중요한 이정표를 남깁니다.

**"Deep" Contextualized Representation:** 최상위 레이어만 쓰는 것이 아니라 모든 레이어를 태스크별로 가중합한다는 아이디어가 핵심입니다. 단순한 아이디어이지만 일관되게 성능 향상을 이끌어냅니다.

**준지도 학습(Semi-supervision) 패러다임 확립:** 레이블 없는 대규모 텍스트로 biLM을 사전 학습한 뒤, 기존 모델에 손쉽게 통합하여 여러 태스크에서 동시에 이득을 얻는 구조는 이후 BERT, GPT 등 대규모 사전 학습 언어 모델의 직접적인 선구자가 됩니다.

**BERT로 이어지는 흐름:** ELMo는 biLSTM 기반의 맥락화 표현을 제안했지만, Transformer 기반으로 더 깊고 효율적인 양방향 사전 학습을 구현한 것이 BERT(2018)입니다. Seq2Seq → Attention → ELMo → BERT로 이어지는 흐름에서 ELMo는 "사전 학습된 표현을 기존 모델에 통합한다"는 패러다임을 처음으로 대규모로 검증한 논문이라는 점에서 의미가 큼니다.



공감

Tag

biLM

CoVe

Deep contextualized word representations

elmo

LSTM

'카테고리 없음'의 다른글

이전글 [\[ Paper Review \] Sequence to Sequence Learning with Neural Networks \(Seq2Seq\)](#)

현재글 : [\[ Paper Review \] Deep Contextualized Word Representations \(ELMo\)](#)

다음글 [\[ Paper Review \] Attention Is All You Need \(Transformer\)](#)

autumnqp 님의 블로그

autumnqp 님의 블로그 입니다.

댓글 0



**autumnqp**

이력서



**autumnqp 님의 블로그**  
autumnqp 님의 블로그 입니다.

글쓰기

블로그 관리

분류 전체보기 (6) 

Paper review (0)

## Tag

NMT, NLP, gpt-1, RNN, CoVe, fine-tuning,  
Bleu, encoder-decoder, LLM, LSTM,  
Deep contextualized word representations, biLM,  
BERT, elmo, Seq2Seq,

Convolutional Neural Networks, DNNs, CLS,  
Attention, Transformer

최근글 인기글

[ Paper Review ] BERT: Pre-training of Deep  
Bidirectional Transformers...

2026.05.06 22:36

[ Paper Review ] Improving  
Language Understanding by  
Generative Pre-Tr...

2026.05.06 21:45

[ Paper Review ] Attention Is All You  
Need (Transformer)

2026.05.06 20:03

최근댓글

공지사항

Facebook Twitter

## Archives

2026/05

2026/04

〈 2026. 05 〉

일 월 화 수 목 금 토

1 2

|    |    |    |          |    |    |    |
|----|----|----|----------|----|----|----|
| 3  | 4  | 5  | <u>6</u> | 7  | 8  | 9  |
| 10 | 11 | 12 | 13       | 14 | 15 | 16 |
| 17 | 18 | 19 | 20       | 21 | 22 | 23 |
| 24 | 25 | 26 | 27       | 28 | 29 | 30 |
| 31 |    |    |          |    |    |    |

Total

4

Today : 1

Yesterday : 2

검색내용을 입력하세요.