

autumnqp 님의 블로그

Search...

메뉴바를 클릭하면
계정을 관리할 수 있어요

카테고리 없음

[Paper Review] Neural Machine Translation by Jointl

autumnqp 2026. 4. 29. 19:24

Bahdanau, D., Cho, K., & Bengio, Y. (2015). Neural Machine Translation by Jointly Learning to Align and Translate. ICLR 2015.

<https://arxiv.org/abs/1409.0473>

1. Introduction — 왜 이 논문이 나왔는가?

기존의 신경망 기계 번역(NMT)은 대부분 인코더-디코더(**Encoder-Decoder**) 구조를 따릅니다. 인코더가 소스 문장 전체를 읽어 하나의 고정 길이 벡터(**fixed-length vector**)로 압축하면,

디코더가 그 벡터에서 번역문을 생성하는 방식이죠.

문제는 여기서 발생합니다. 문장이 길어질수록 모든 정보를 단 하나의 고정 크기 벡터에 담는 것은 구조적으로 무리가 있습니다. 실제로 Cho et al. (2014)는 입력 문장의 길이가 늘어날수록 기본 인코더-디코더의 성능이 급격히 떨어진다는 것을 보였습니다.

이 논문은 그 병목(bottleneck) 문제를 해결하기 위해, 디코더가 번역 시 소스 문장의 **관련 있는 부분을 자동으로 찾아 집중(attend)** 하도록 하는 새로운 아키텍처를 제안합니다. 이것이 바로 **Attention Mechanism**의 시작입니다.

2. Background — 기존 RNN Encoder-Decoder

기존 모델의 구조를 간단히 정리하면 다음과 같습니다.

- **인코더**: 소스 문장 $x = (x_1, \dots, x_{T_x})$ 를 순서대로 읽으며 은닉 상태를 업데이트하고, 마지막 은닉 상태를 고정 길이 벡터 c 로 만듭니다.
- **디코더**: 해당 벡터 c 를 기반으로 타겟 단어를 하나씩 생성합니다.

$$p(y_t \mid y_1, \dots, y_{t-1}, c) = g(y_{t-1}, s_t, c)$$

이 구조의 핵심 한계는 디코더가 번역 내내 **동일한 하나의 벡터 c** 만 참조한다는 점입니다. 소스 문장이 50 단어 이상이 되면, 단 하나의 벡터로 모든 정보를 전달하는 것은 사실상 불가능합니다.

3. Proposed Model — Attention 메커니즘


이 논문에서 제안하는 RNNsearch 모델은 크게 두 가지 구성 요소로 이루어져 있습니다.

3.1 Encoder: Bidirectional RNN

기존의 단방향 RNN 대신 **양방향 RNN(BiRNN)** 을 사용합니다. 순방향 RNN은 x_1 부터 x_{T_x} 까지, 역방향 RNN은 x_{T_x} 부터 x_1 까지 읽습니다. 두 방향의 은닉 상태를 이어 붙여(concatenate) 각 단어에 대한 **어노테이션(annotation)** h_j 를 만듭니다.

$$h_j = [\vec{h}_j; \overleftarrow{h}_j]$$

이를 통해 각 어노테이션은 해당 단어의 앞뒤 문맥 정보를 모두 담게 됩니다.



3.2 Decoder: Attention Mechanism

기존과 달리, 타겟 단어 y_i 를 생성할 때마다 **고유한 컨텍스트 벡터** c_i 를 계산합니다.

$$p(y_i | y_1, \dots, y_{i-1}, x) = g(y_{i-1}, s_i, c_i)$$

컨텍스트 벡터 c_i 는 모든 소스 어노테이션의 **가중합**입니다.

$$c_i = \sum_{j=1}^{T_x} \alpha_{ij} h_j$$

이때 가중치 α_{ij} 는 소프트맥스를 통해 정규화됩니다.

$$\alpha_{ij} = \frac{\exp(e_{ij})}{\sum_{k=1}^{T_x} \exp(e_{ik})}, \quad e_{ij} = a(s_{i-1}, h_j)$$

정렬 모델 a 는 이전 디코더 은닉 상태 s_{i-1} 와 소스 어노테이션 h_j 의 관련도를 계산하는 피드포워드 신경망입니다.

$$e_{ij} = v_a^\top \tanh(W_a s_{i-1} + U_a h_j)$$

α_{ij} 를 "타겟 단어 y_i 가 소스 단어 x_j 에 정렬될 확률"로 해석할 수 있으며, c_i 는 그 확률로 가중된 어노테이션의 기댓값이 됩니다.

핵심 아이디어: 인코더가 모든 정보를 하나의 벡터에 억지로 압축할 필요 없이, 디코더가 매 스텝마다 소스 문장에서 필요한 정보를 선택적으로 가져옵니다.

4. Experiment Settings

- 데이터셋: ACL WMT '14 영어-프랑스어 병렬 코퍼스 (약 3억 4800만 단어)
- 어휘: 각 언어별 빈도 상위 30,000 단어 사용, 나머지는 [UNK]로 처리
- 비교 모델:
 - RNNencdec-30 / 50: 기존 인코더-디코더 (최대 30, 50 단어 학습)
 - RNNsearch-30 / 50: 제안 모델 (최대 30, 50 단어 학습)
 - Moses: 전통적인 구문 기반 통계 기계 번역(phrase-based SMT) 시스템
- 학습: 미니배치 SGD + Adadelta, 배치 크기 80문장, 약 5일 학습
- 평가 지표: BLEU score

5. Results

5.1 Quantitative Results


Model	All	No UNK ^o
RNNencdec-30	13.93	24.19
RNNsearch-30	21.50	31.44
RNNencdec-50	17.82	26.71
RNNsearch-50	26.75	34.16
RNNsearch-50*	28.45	36.15
Moses	33.30	35.63

표의 주요 결과를 요약하면 다음과 같습니다.


모델전체 문장 BLEUUNK 제외 BLEU

RNNencdec-30	13.93	24.19
RNNsearch-30	21.50	31.44
RNNencdec-50	17.82	26.71
RNNsearch-50	26.75	34.16
RNNsearch-50*	28.45	36.15
Moses	33.30	35.63


RNNsearch-30이 RNNencdec-50보다 높은 성능을 보이는 점이 인상적입니다. 또한 UNK 없는 문장만 평가했을 때 RNNsearch-50*은 Moses와 거의 동등한 수준에 도달합니다.




5.2 Qualitative Analysis — Soft Alignment 시각화




(a)



(b)



(c)



(d)

단조 정렬(monotonic alignment): 대부분의 단어는 대각선 방향으로 정렬됩니다. 영어와 프랑스어의 어순이 대체로 유사하기 때문입니다.

비단조 정렬(non-monotonic alignment): 형용사-명사 순서가 두 언어 간에 반전되는 경우도 모델이 올바르게 처리합니다. 예를 들어 [European Economic Area]를 [zone économique européenne]으로 번역할 때 단어 순서가 뒤바뀌어도 정확히 정렬됩니다.

Soft alignment의 장점: 예시 (d)에서 영어 [the man]을 프랑스어 [l' homme]으로 번역할 때, [the]를 번역하려면 뒤에 오는 [man]을 함께 봐야 [le/la/les/l'] 중 무엇인지 결정할 수 있습니다. Hard alignment는 이를 처리하기 어렵지만, soft alignment는 [the]와 [man]을 동시에

참조하여 [1]을 올바르게 생성합니다.

6. 결론 및 의의

이 논문은 다음 세 가지 측면에서 NMT 역사에서 중요한 전환점이 됩니다.

고정 길이 벡터 병목 해결: 소스 문장 전체를 하나의 벡터로 압축하는 대신, 디코더가 매 스텝마다 소스 어노테이션 시퀀스 전체를 동적으로 참조합니다.

End-to-End 공동 학습: 정렬 모델(alignment model)과 번역 모델이 별도로 학습되는 것이 아니라, 역전파(backpropagation)를 통해 전체 시스템이 한 번에 학습됩니다. 기존 SMT처럼 각 구성 요소를 개별 튜닝할 필요가 없습니다.

Transformer의 직접적 선구자: 이 논문에서 제안한 attention 메커니즘은 이후 "Attention Is All You Need" (Transformer, 2017)의 핵심 개념으로 발전합니다. Transformer는 RNN을 완전히 제거하고 attention만으로 아키텍처를 구성하는 방향으로 나아갔습니다.

공감

Tag

Attention

encoder-decoder

NMT

RNN

'카테고리 없음'의 다른글

현재글 : [Paper Review] Neural Machine Translation by Jointly Learning to Align and Translate (Attention)

다음글 [Paper Review] Sequence to Sequence Learning with Neural Networks (Seq2Seq)

autumnqp 님의 블로그

autumnqp 님의 블로그 입니다.

댓글 0



autumnqp

댓글



autumnqp 님의 블로그

autumnqp 님의 블로그 입니다.

글쓰기

블로그 관리

분류 전체보기 (6) 

Paper review (0)

Tag

encoder-decoder, Bleu, DNNs, elmo, gpt-1,
NMT, LSTM, fine-tuning, Attention, CoVe, LLM,
RNN, Seq2Seq, Convolutional Neural Networks,
CLS, Transformer, biLM,
Deep contextualized word representations, NLP,
BERT

최근글 인기글

[Paper Review] BERT: Pre-training of Deep
Bidirectional Transformers...

2026.05.06 22:36

[Paper Review] Improving
Language Understanding by
Generative Pre-Tr...

2026.05.06 21:45

[Paper Review] Attention Is All You
Need (Transformer)

2026.05.06 20:03

최근댓글

공지사항

Facebook Twitter

Archives

2026/05

2026/04

〈 2026. 05 〉						
일	월	화	수	목	금	토
					1	2
3	4	5	<u>6</u>	7	8	9
10	11	12	13	14	15	16
17	18	19	20	21	22	23
24	25	26	27	28	29	30
31						

Total

4

Today : 1

Yesterday : 2

검색내용을 입력하세요.