

autumnqp 님의 블로그

Search...

메뉴바를 클릭하면
계정을 관리할 수 있어요

카테고리 없음

[Paper Review] Sequence to Sequence Learning with Neur

autumnqp 2026. 4. 29. 20:15

논문 링크

Sutskever, I., Vinyals, O., & Le, Q. V. (2014). Sequence to Sequence Learning with Neural Networks. NeurIPS 2014. <https://arxiv.org/abs/1409.3215>

1. Introduction — 왜 이 논문이 나왔는가?

딥 뉴럴 네트워크(DNN)는 음성 인식, 이미지 분류 등 다양한 분야에서 뛰어난 성능을 보여왔습니

다. 그러나 DNN에는 근본적인 한계가 있었는데, 바로 **입력과 출력의 차원이 고정되어 있어야 한다**는 점입니다.

기계 번역처럼 입력 문장과 출력 문장의 길이가 서로 다르고, 사전에 알 수 없는 **가변 길이 시퀀스**를 다루는 문제에는 기존 DNN을 그대로 적용하기 어려웠습니다.

이 논문은 그 한계를 극복하기 위해, **하나의 LSTM으로 입력 시퀀스를 고정 차원 벡터로 압축하고, 또 다른 LSTM으로 해당 벡터에서 출력 시퀀스를 생성하는** 엔드-투-엔드(end-to-end) Seq2Seq 아키텍처를 제안합니다.

2. Background — RNN과 LSTM

기본적인 RNN은 시퀀스를 순차적으로 처리할 수 있지만, 입력과 출력의 길이가 다르고 관계가 비단조적(non-monotonic)인 경우에는 적용하기 어렵습니다. 또한 긴 시퀀스에서는 **기울기 소실(vanishing gradient)** 문제로 인해 장기 의존성 학습이 어렵습니다.

LSTM(Long Short-Term Memory) 은 게이트 메커니즘을 통해 이 문제를 해결합니다. 장기 의존성을 효과적으로 학습할 수 있어, 긴 입력-출력 사이의 시간 간격이 큰 Seq2Seq 문제에 자연스럽게 적합합니다.

3. Proposed Model — Seq2Seq 아키텍처

3.1 전체 구조

핵심 수식은 다음과 같습니다.

$$p(y_1, \dots, y_{T'} \mid x_1, \dots, x_T) = \prod_{t=1}^{T'} p(y_t \mid v, y_1, \dots, y_{t-1})$$

- **인코더 LSTM**: 입력 시퀀스 $(x_1, \dots, x_T)$ 를 순서대로 읽고, 마지막 은닉 상태를 고정 차원 벡터 v 로 사용합니다. 이 벡터가 입력 문장 전체의 의미를 담습니다.
- **디코더 LSTM**: 벡터 v 를 초기 은닉 상태로 받아, 매 스텝마다 조건부 확률 $p(y_t \mid v, y_1, \dots, y_{t-1})$ 을 소프트맥스로 계산하며 출력 시퀀스를 생성합니다.
- 출력 시퀀스의 끝은 특별 토큰 <EOS>로 정의합니다.

3.2 세 가지 핵심 설계 선택

① 인코더와 디코더를 별개의 LSTM으로 분리

인코딩과 디코딩을 하나가 아닌 두 개의 독립적인 LSTM으로 처리합니다. 파라미터 수가 늘어나 표현력이 증가하고, 다국어 학습에도 유리합니다.

② 심층 LSTM(4 레이어) 사용

얕은 LSTM보다 심층 LSTM이 훨씬 우수한 성능을 보였습니다. 레이어를 하나 추가할 때마다 perplexity가 약 10%씩 감소했습니다. 최종적으로 4레이어, 레이어당 1,000개 유닛, 1,000차원 워드 임베딩을 사용해 총 3억 8,400만 개의 파라미터를 가집니다.

③ 소스 문장 단어 순서 역전 (핵심 기여)

이 논문의 가장 독창적인 기여입니다. 예를 들어 소스 문장 a, b, c 를 타겟 α, β, γ 로 번역할 때, 입력을 c, b, a 로 뒤집어서 학습합니다.

이 트릭의 효과는 다음과 같이 설명됩니다. 원래 소스와 타겟을 이어붙이면 소스의 첫 단어가 타겟의 첫 단어와 멀리 떨어져 있어 최적화가 어렵습니다. 역전하면 소스의 첫 단어 c 가 타겟의 첫 단어 α 와 가까워져 **단기 의존성(short-term dependency)**이 생기고, 역전파가 입력-출력 간 연결을 훨씬 쉽게 학습합니다. 실제로 이 트릭 하나로 테스트 perplexity가 5.8에서 4.7로, BLEU 점수가 25.9에서 30.6으로 크게 향상되었습니다.

4. Experiment Settings

- **데이터셋:** WMT'14 영어-프랑스어 번역 태스크, 1,200만 문장 쌍 (3억 4,800만 프랑스어 단어, 3억 400만 영어 단어)
- **어휘:** 소스 16만 단어, 타겟 8만 단어, 나머지는 UNK 처리
- **모델 구조:** 4레이어 심층 LSTM, 레이어당 1,000개 유닛, 총 384M 파라미터
- **학습:** SGD (모멘텀 없음), 학습률 0.7 (5 에포크 후 매 반 에포크마다 절반으로 감소), 총 7.5 에포크
- **기울기 클리핑:** 그래디언트 노름이 5를 초과하면 스케일링
- **디코딩:** 빔 서치 (beam search), 빔 크기 12
- **병렬화:** 8-GPU 머신, GPU당 LSTM 레이어 1개 배치, 학습에 약 10일 소요
- **평가 지표:** cased BLEU score

5. Results

5.1 Quantitative Results

주요 결과를 요약하면 다음과 같습니다.

SMT Baseline (Moses)	33.30
단일 역전 LSTM (빔 12)	30.59
양상블 5개 역전 LSTM (빔 12)	34.81
SMT 1000-best 재점수화 (양상블)	36.5
WMT'14 최고 결과	37.0

순수 신경망 모델이 처음으로 대규모 번역 태스크에서 SMT 베이스라인(33.30)을 넘어선 34.81 BLEU를 달성한 것이 이 논문의 핵심 성과입니다. 또한 SMT 시스템이 생성한 1,000-best 리스트를 LSTM으로 재점수화(rescoring)하면 36.5까지 올라가 당시 최고 결과(37.0)에 근접합니다.

흥미로운 점은 빔 크기 2만 해도 빔 크기 12의 대부분의 이점을 얻을 수 있고, 빔 크기 1에서도 준수한 성능을 보인다는 것입니다.

5.2 긴 문장에서의 성능

기존 연구들과 달리, 이 모델은 35단어 이하 문장에서 성능 저하가 전혀 없고, 그 이상의 긴 문장에서도 소폭의 저하만 있었습니다. 소스 문장 역전 트릭 덕분에 LSTM이 긴 문장에서도 메모리를 효율적으로 활용할 수 있었습니다.

5.3 모델의 내부 표현 분석

LSTM이 학습한 고정 차원 벡터 표현을 PCA로 2차원으로 투영한 결과, 두 가지 흥미로운 특성을 확인할 수 있습니다. 단어 순서에 민감하여 "John respects Mary"와 "Mary respects John"은 다른 위치에 있고, 능동태/수동태 변환에는 상대적으로 불변하여 "I gave her a card"와 "She was given a card by me"는 가까운 위치에 있습니다.

6. 결론 및 의의

이 논문은 세 가지 측면에서 중요한 기여를 합니다.

순수 신경망의 SMT 최초 능가: 제한된 어휘와 최소한의 구조적 가정만으로도 대규모 기계 번역에서 SMT를 넘어설 수 있음을 처음으로 증명했습니다.

소스 문장 역전 트릭: 단순한 데이터 전처리 하나가 BLEU를 약 5점 향상시킬 수 있다는 것은 놀라운 발견입니다. 이는 최적화 문제의 구조를 바꾸는 것이 얼마나 강력한 효과를 낼 수 있는지 보여줍니다.

Attention 메커니즘으로의 연결: 이 논문의 핵심 한계는 모든 정보를 단 하나의 고정 벡터 v 에 압축해야 한다는 점입니다. 이 한계를 극복하기 위해 Bahdanau et al.(2015), 즉 앞서 리뷰한 Attention 논문이 등장하게 됩니다. 두 논문을 함께 읽으면 Attention 메커니즘이 왜 필요했는지 그 맥락을 더 잘 이해할 수 있습니다.

1

Tag

DNNs

encoder-decoder

LSTM

Seq2Seq

'카테고리 없음'의 다른글

이전글 [Paper Review] Neural Machine Translation by Jointly Learning to Align and Translate (Attention)

현재글 : [Paper Review] Sequence to Sequence Learning with Neural Networks (Seq2Seq)

다음글 [Paper Review] Deep Contextualized Word Representations (ELMo)

autumnqp 님의 블로그

autumnqp 님의 블로그 입니다.

댓글 0



등록



autumnqp 님의 블로그

autumnqp 님의 블로그 입니다.

글쓰기

블로그 관리

분류 전체보기 (6) 

Paper review (0)

Tag

Seq2Seq, Convolutional Neural Networks, LLM,
NLP, Bleu, DNNs, CoVe, LSTM, gpt-1, CLS,
BERT, Deep contextualized word representations,
NMT, fine-tuning, elmo, Attention,
encoder-decoder, biLM, Transformer, RNN

최근글 인기글

[Paper Review] BERT: Pre-training of Deep
Bidirectional Transformers...

2026.05.06 22:36

[Paper Review] Improving
Language Understanding by
Generative Pre-Tr...

2026.05.06 21:45

[Paper Review] Attention Is All You
Need (Transformer)

2026.05.06 20:03

최근댓글

공지사항

Facebook Twitter

Archives

2026/05

2026/04

〈 2026. 05 〉						
일	월	화	수	목	금	토
					1	2
3	4	5	<u>6</u>	7	8	9
10	11	12	13	14	15	16
17	18	19	20	21	22	23
24	25	26	27	28	29	30
31						

Total

4

Today : 1

Yesterday : 2

검색내용을 입력하세요.