

autumnqp 님의 블로그

Search...

메뉴바를 클릭하면
계정을 관리할 수 있어요

카테고리 없음

[Paper Review] BERT: Pre-training of Deep

autumnqp 2026. 5. 6. 22:36

논문 링크

Devlin, J., Chang, M.-W., Lee, K., & Toutanova, K. (2018). BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding. Google AI Language. <https://arxiv.org/pdf/1810.04805>

1. Introduction

언어 모델 사전 학습은 이미 NLP의 표준이 되어 있었습니다. ELMo(2018)는 biLSTM으로 문맥화된 표현을 제공했고, GPT-1(2018)은 Transformer 디코더 + 파인튜닝 패러다임을 확립했습니다. 그러나 BERT 저자들은 이들이 공유하는 결정적 한계 하나를 정조준합니다. **사전 학습 단계**

에서 모델이 단방향(**unidirectional**)이라는 점입니다.

GPT-1은 왼쪽에서 오른쪽으로만 다음 단어를 예측합니다. 즉, Self-Attention에서 각 토큰은 자신보다 앞에 있는 토큰만 참조할 수 있습니다. ELMo는 left-to-right LM과 right-to-left LM을 독립적으로 학습한 뒤 단순히 concatenate하는 "shallow bidirectional" 구조에 그칩니다. 저자들의 주장은 명확합니다.

- **문장 수준 태스크(NLI, 감성 분석)**: 한 단어를 이해하려면 좌·우 문맥을 동시에 봐야 함
- **토큰 수준 태스크(QA, NER)**: 단방향 제약은 치명적 — 질문 응답에서 답을 찾을 때 답 뒤에 오는 문맥도 결정적

BERT는 **Masked Language Model(MLM)**이라는 단순하지만 천재적인 아이디어로 이 문제를 해결합니다. 입력의 일부 토큰을 랜덤으로 가리고([MASK]), 좌·우 문맥을 모두 활용해 가려진 단어를 맞히게 함으로써 진정한 **deep bidirectional** Transformer 사전 학습을 가능케 한 것입니다. 결과는 압도적이었습니다. 11개 NLP 태스크에서 SOTA, GLUE 점수를 80.5%로 끌어올리며(+7.7%p) NLP의 새 시대를 엽니다.

2. Background

BERT 이전 사전 학습 활용 방식은 두 갈래로 나뉩니다.

Feature-based (대표: ELMo) — 사전 학습된 표현을 고정된 feature로 뽑아 태스크별 아키텍처에 추가 입력으로 주입. 태스크마다 별도 모델 설계가 필요.

Fine-tuning (대표: GPT-1) — 최소한의 태스크별 파라미터(보통 출력 레이어 하나)만 추가하고, 사전 학습 파라미터 전체를 다운스트림 태스크에 함께 학습.

모델아키텍처방향성전이 방식

ELMo	biLSTM	shallow bidirectional (concat)	feature-based
GPT-1	Transformer Decoder	unidirectional (L→R)	fine-tuning
BERT	Transformer Encoder	deep bidirectional	fine-tuning

BERT의 정체성은 이 표 한 줄로 요약됩니다. **GPT-1의 fine-tuning 패러다임을 그대로 계승하되, 단방향 제약을 제거한 모델**입니다.

3. BERT — 모델 구조와 핵심 아이디어

3.1 모델 아키텍처

BERT는 **multi-layer bidirectional Transformer Encoder**입니다. Vaswani et al. (2017)의 원조 Transformer 인코더를 거의 그대로 사용합니다. 두 가지 사이즈로 공개됩니다.

모델 Layers (L) Hidden (H) Heads (A) Params

BERT-BASE	12	768	12	110M
BERT-LARGE	24	1024	16	340M

BERT-BASE는 GPT-1과 동일한 크기로 설정되어 **공정한 비교**가 가능하도록 의도되었습니다. 차이는 오직 **인코더(양방향) vs 디코더(단방향)** 뿐입니다.

3.2 Input Representation — 단일 문장과 문장 쌍을 모두 처리하기

- [CLS]: 모든 시퀀스의 첫 토큰. 이 위치의 최종 hidden state가 **분류 태스크의 aggregate 표현**으로 사용됨
- [SEP]: 문장 쌍을 구분하는 분리 토큰

입력 임베딩은 세 가지 임베딩의 합으로 구성됩니다.

$$E_{input} = E_{token} + E_{segment} + E_{position}$$

- **Token Embedding:** WordPiece 토큰나이저(30,000 어휘)
- **Segment Embedding:** 첫 번째 문장은 EAEA, 두 번째 문장은 EBEB
- **Position Embedding:** 학습된 위치 임베딩 (최대 512)

이 단순한 입력 형식 덕분에 BERT는 **GPT-1**처럼 **태스크별 입력 변환을 따로 설계할 필요가 거의 없습니다.**

3.3 Pre-training Task #1 — Masked Language Model (MLM)

BERT의 핵심 혁신입니다. 표준 LM은 단방향이지만, MLM은 입력의 일부 토큰을 가리고 양방향 문맥으로 복원하므로 **deep bidirectional** 학습이 가능합니다. 구체적으로 입력 토큰의 **15%**를 무작위 선택해 다음과 같이 처리합니다.

- **80%:** [MASK] 토큰으로 치환
- **10%:** 랜덤한 다른 토큰으로 치환
- **10%:** 그대로 유지

왜 단순히 100% [MASK]로 치환하지 않을까요? 파인튜닝 단계에서는 [MASK] 토큰이 등장하지 않기 때문입니다. 사전 학습과 파인튜닝의 **mismatch**를 줄이기 위한 설계입니다. 10%를 랜덤 토큰으로 바꿈으로써 모델이 모든 입력 토큰을 신뢰할 수 없게 만들어, **모든 위치에 대해 분산된 문맥 표현**을 학습하도록 강제합니다.

손실 함수는 가려진 토큰에 대한 cross-entropy만 계산합니다.

$$L_{MLM} = -\sum_{i \in M} \log P(x_i | x_{\sim}; \Theta) \quad L_{MLM} = -i \in M \sum \log P(x_i | x_{\sim}; \Theta)$$

여기서 MM은 마스킹된 위치 집합, $x_{\sim}$ 는 마스킹된 입력 시퀀스입니다.

3.4 Pre-training Task #2 — Next Sentence Prediction (NSP)

QA, NLI 같은 많은 태스크는 **두 문장의 관계**를 이해해야 합니다. 단순 LM은 이 관계를 명시적으로 학습하지 않으므로, BERT는 보조 태스크 NSP를 도입합니다. 학습 시 문장 쌍 (A, B)를 다음과 같이 구성합니다.

- **50%:** B가 실제 A의 다음 문장 → 레이블 IsNext
- **50%:** B가 코퍼스에서 무작위로 뽑힌 문장 → 레이블 NotNext

[CLS] 토큰의 최종 hidden state $C \in \mathbb{R}^H$ 를 이용해 이진 분류를 수행합니다. 단순한 태스크지만, QA·NLI 성능에 실질적 도움이 됨을 후속 ablation에서 보여줍니다. (다만 RoBERTa(2019) 등 후속 연구에서 NSP의 효용이 의심받게 됩니다.)

3.5 Pre-training Data

- **BooksCorpus** (800M 단어) — GPT-1과 동일
- **English Wikipedia** (2,500M 단어) — 본문만, 리스트·표·헤더 제외

총 약 **3.3B** 단어로, GPT-1의 BooksCorpus(800M)에 비해 4배 이상 큼니다.

3.6 Fine-tuning — 하나의 모델, 모든 태스크

GPT-1이 태스크마다 입력 토큰 시퀀스를 변환해야 했다면, BERT는 **입력 형식이 이미 충분히 일반적**이라 거의 변환이 필요 없습니다.

- **분류 (단일 문장 / 문장 쌍):** [CLS]의 최종 표현 CC 위에 분류 레이어 $W \in \mathbb{R}^{K \times H}, H \in \mathbb{R}^{K \times H}$ 추가
- **토큰 단위 태스크 (NER):** 각 토큰의 최종 표현 T_i 위에 분류 레이어
- **QA (SQuAD):** 답의 시작/끝 위치를 예측하는 두 벡터 $S, E \in \mathbb{R}^H, E \in \mathbb{R}^H$ 학습. 토큰 i 가 답 시작일 확률 $= e^{S \cdot T_i} / \sum_j e^{S \cdot T_j} \cdot e^{E \cdot T_j} / \sum_k e^{E \cdot T_k}$

파인튜닝은 모든 태스크에서 **2~4 에포크**, 매우 저렴합니다.

4. Experiment Settings

- **Pre-training 데이터:** BooksCorpus(800M) + English Wikipedia(2,500M) = 3.3B 단어
- **시퀀스 길이:** 최대 512 토큰, 배치 256
- **스텝:** 1,000,000 (약 40 에포크)
- **옵티마이저:** Adam ($\text{lr} = 1e-4, \beta_1=0.9, \beta_2=0.999, \text{L2 weight decay } 0.01$)
- **Warmup:** 처음 10,000 스텝 선형 warmup, 이후 선형 감소
- **Dropout:** 0.1 (모든 레이어)
- **활성화 함수:** GELU (GPT-1과 동일)
- **하드웨어:** BERT-BASE는 4 Cloud TPU(16 chips) × 4일, BERT-LARGE는 16 Cloud TPU(64 chips) × 4일
- **Fine-tuning:** 배치 16~32, $\text{lr } 5e-5/3e-5/2e-5$ 중 선택, 2~4 에포크

5. Results

5.1 GLUE — 문장 수준 이해의 종합 평가

모델AverageMNLI-mQNLISSST-2CoLA

Pre-OpenAI SOTA	74.0	80.6	82.3	93.2	35.0
OpenAI GPT-1	75.1	82.1	88.1	91.3	45.4
BERT-BASE	79.6	84.6	90.5	93.5	52.1
BERT-LARGE	82.1	86.7	92.7	94.9	60.5

BERT-BASE가 동일한 크기의 **GPT-1**보다 평균 **4.5점** 향상했다는 점이 핵심입니다. 모델 크기가 같으므로 이 차이는 전적으로 **양방향 사전 학습의 효과**입니다. BERT-LARGE는 GLUE를 80.5%로 끌어올려 +7.7%p의 절대 향상을 달성합니다.

5.2 SQuAD — Question Answering

모델EMF1

이전 SOTA (양상블)	86.0	91.7
BERT-LARGE (단일)	84.1	90.9
BERT-LARGE (양상블)	87.4	93.2

SQuAD v2.0에서는 더욱 인상적입니다. F1 83.1을 달성하며 이전 SOTA 대비 +5.1점 향상. QA처럼 답 뒤 문맥까지 봐야 하는 토큰 수준 태스크에서 양방향 사전 학습의 위력이 가장 극적으로 드러납니다.

5.3 SWAG — 상식 추론

상식 기반 문장 완성 태스크. BERT-LARGE는 86.3%로 인간 전문가(85.0%)를 능가하며 GPT-1(78.0%) 대비 +8.3%p 향상.

6. Analysis — BERT의 성공 요인 해부

6.1 Ablation: Pre-training Task의 효과

모델 MNLI QNLI MRPC SST-2 SQuAD F1

BERT-BASE	84.4	88.4	86.7	92.7	88.5
No NSP	83.9	84.9	86.5	92.6	87.9
LTR & No NSP (≈ GPT 재현)	82.1	84.3	77.5	92.1	77.8
+ BiLSTM (LTR 위에)	82.1	84.1	75.7	91.6	84.9

핵심 발견 두 가지입니다.

1. **MLM(양방향)의 효과가 압도적** — LTR 모델은 SQuAD에서 F1 77.8로 BERT-BASE(88.5) 대비 **10점 이상 폭락**. QA처럼 토큰 수준 태스크에서 단방향이 얼마나 치명적인지 명확히 보여줍니다.
2. **NSP 제거 시 QNLI, SQuAD 등 문장 관계 태스크에서 명확한 하락** — 작지만 일관된 효과.

6.2 모델 크기의 효과

저자들은 모델을 키울수록 **소규모 데이터셋에서도 일관된 향상**이 일어남을 보입니다. 당시 통념은 "큰 모델은 큰 데이터에서만 도움"이었으나, 충분한 사전 학습이 있다면 **작은 다운스트림 데이터셋에서도 거대 모델이 유리함**을 처음으로 명확히 입증합니다. 이는 이후 GPT-2/3의 스케일링 흐름의 이론적 기반이 됩니다.

6.3 Feature-based vs. Fine-tuning

BERT의 마지막 4개 레이어 표현을 concat해 feature-based로 사용해도 F1 96.1을 달성, 파인튜닝(96.4)에 거의 근접. **BERT는 fine-tuning과 feature-based 양쪽 모두에서 작동**한다는 강력한 증거입니다.

7. 결론 및 의의

BERT의 기여는 세 가지로 요약됩니다.

1. **Deep Bidirectional Pre-training의 실현** — MLM이라는 단순한 아이디어로 진짜 양방향 Transformer를 사전 학습 가능하게 만들었습니다. ELMo의 shallow bidirectional, GPT-1의 unidirectional을 모두 뛰어넘는 본질적 진보입니다.
2. **One Model, Many Tasks** — 동일한 사전 학습 모델 + 출력 레이어 하나로 11개 태스크에서 SOTA. 태스크별 아키텍처 설계의 시대가 종료됩니다.
3. **스케일링 가설의 실증** — 모델을 키울수록 모든 태스크에서 일관된 향상. 이는 GPT-2(2019), GPT-3(2020), T5(2020) 등 후속 거대 모델 흐름의 출발점이 됩니다.

지금까지 이어진 흐름을 정리하면 다음과 같습니다.

Seq2Seq (2014) → Bahdanau Attention (2015) → **Transformer**
(2017) → ELMo (2018, biLSTM·shallow biLM) → **GPT-1 (2018,**
Transformer Decoder·unidirectional·fine-tuning) → **BERT (2018,**
Transformer Encoder·deep bidirectional·MLM) →
RoBERTa·ALBERT·T5·GPT-2/3 ...

GPT-1이 "**Pre-train then Fine-tune**" 패러다임을 확립했다면, BERT는 그 패러다임을 **양방향**이라는 한 차원 위로 끌어올려 NLP 전체를 재편했습니다. 흥미로운 점은 이후 역사가 두 갈래로 갈라진다는 것입니다. **이해(Understanding) 계열은 BERT의 인코더 방향**(RoBERTa, ELECTRA 등)으로, **생성(Generation) 계열은 GPT의 디코더 방향**(GPT-2/3/4)으로 발전합니다. 그리고 결국 GPT 계열이 거대 스케일에서 이해 능력까지 흡수하며 LLM 시대의 주류가 되지만, 그 출발점에서 BERT가 보여준 "양방향 사전 학습의 힘"은 여전히 NLP 사전 학습의 근본 원리로 남아 있습니다.

공감

Tag

BERT

CLS

LLM

NLP

Transformer

'카테고리 없음'의 다른글

이전글 [Paper Review] Improving Language Understanding by Generative Pre-Training (GPT-1)

현재글 : [Paper Review] BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding

autumnqp 님의 블로그

autumnqp 님의 블로그 입니다.

댓글 0



autumnqp

댓글



autumnqp 님의 블로그

autumnqp 님의 블로그 입니다.

글쓰기

블로그 관리

분류 전체보기 (6) 

Paper review (0)

Tag

NLP, Bleu, LLM, DNNs, CLS, elmo,
Transformer, gpt-1,
Deep contextualized word representations,
fine-tuning, BERT, NMT, LSTM,
Convolutional Neural Networks, RNN, CoVe,
Attention, biLM, Seq2Seq, encoder-decoder

최근글 인기글

[Paper Review] BERT: Pre-training of Deep
Bidirectional Transformers...

2026.05.06 22:36

[Paper Review] Improving
Language Understanding by
Generative Pre-Tr...

2026.05.06 21:45

[Paper Review] Attention Is All You
Need (Transformer)

2026.05.06 20:03

최근댓글

공지사항

Facebook Twitter

Archives

2026/05

2026/04

〈 2026. 05 〉

일	월	화	수	목	금	토
					1	2
3	4	5	<u>6</u>	7	8	9
10	11	12	13	14	15	16
17	18	19	20	21	22	23
24	25	26	27	28	29	30
31						

Total

4

Today : 1

Yesterday : 2

검색내용을 입력하세요.