

autumnqp 님의 블로그

Search...

메뉴바를 클릭하면
계정을 관리할 수 있어요

카테고리 없음

[Paper Review] Improving Language Understanding by

autumnqp 2026. 5. 6. 21:45

논문 링크

Radford, A., Narasimhan, K., Salimans, T., & Sutskever, I. (2018). Improving
Language Understanding by Generative Pre-Training. OpenAI.

https://cdn.openai.com/research-covers/language-unsupervised/language_understanding_paper.pdf

1. Introduction — 레이블 없는 데이터로 언어를 이해할 수 있을까?

NLP에서 지도 학습(supervised learning)은 항상 레이블이 붙은 데이터를 필요로 합니다. 하지만 현실에서 레이블 있는 데이터를 대규모로 확보하는 것은 매우 비용이 크고 시간이 많이 걸립니다. 반면 인터넷에는 레이블 없는 텍스트가 사실상 무한히 존재합니다.

ELMo(2018)는 이 방향으로 중요한 한 걸음을 내딛었습니다. biLSTM으로 사전 학습된 표현을 기존 모델에 추가해 성능을 끌어올렸죠. 그러나 ELMo는 두 가지 한계가 있었습니다.

아키텍처 한계: biLSTM 기반이라 장거리 의존성 학습에 한계가 있습니다. **통합 방식의 한계:** ELMo는 기존 모델에 "추가"하는 형태라, 태스크마다 별도의 아키텍처 설계가 여전히 필요했습니다.

GPT-1은 이 두 한계를 모두 극복합니다. **Transformer 디코더**를 기반으로 대규모 텍스트를 사전 학습(pre-training)하고, 이후 각 태스크에 맞게 **파인튜닝(fine-tuning)** 하는 단순하지만 강력한 2단계 프레임워크를 제안합니다. 모델 구조를 거의 바꾸지 않고 입력 형식만 변환하는 방식으로 12개 태스크 중 9개에서 당시 SOTA를 달성합니다.

2. Background — 사전 학습의 역사와 두 가지 문제

GPT-1 이전에도 비지도 사전 학습을 NLP에 적용하려는 시도들이 있었습니다.

Word2Vec, GloVe: 단어 수준의 표현을 사전 학습. 문맥 독립적이라는 한계 존재.

ELMo: biLM으로 문맥화된 표현 학습. 하지만 최상위 레이어만 쓰거나 모든 레이어를 선형 결합하는 방식이라 태스크 적용 시 여전히 태스크별 아키텍처 필요.

CoVe: 기계 번역 인코더를 활용. 병렬 코퍼스 크기에 제한.

이 논문은 사전 학습 연구에서 두 가지 미해결 질문에 답합니다.

첫째, **어떤 목표 함수(objective)로 사전 학습하는 것이 최적인가?** 언어 모델링, 기계 번역, 담화 일관성 등 다양한 목표가 시도됐지만 태스크마다 결과가 달랐습니다. 이 논문은 언어 모델링(다음 단어 예측)이 가장 범용적임을 보입니다.

둘째, **학습된 표현을 다운스트림 태스크에 어떻게 전달할 것인가?** 기존에는 태스크마다 모델 구조를 바꾸거나 복잡한 학습 방식을 사용했습니다. GPT-1은 입력 형식 변환만으로 동일한 모델을 모든 태스크에 적용합니다.

3. Framework — 두 단계 학습 전략

GPT-1의 학습은 크게 두 단계로 이루어집니다.

3.1 Stage 1 — 비지도 사전 학습 (Unsupervised Pre-training)

레이블 없는 대규모 텍스트 코퍼스 $\mathcal{U} = u_1, \dots, u_n$ 에서 다음 언어 모델 목표를 최대화합니다.

$$L_1(\mathcal{U}) = \sum_i \log P(u_i \mid u_{i-k}, \dots, u_{i-1}; \Theta)$$

k 는 컨텍스트 윈도우 크기이고, 파라미터 Θ 는 SGD로 학습합니다. 핵심은 **다음 단어 예측**이라는 단순한 목표만으로 언어의 구문, 의미, 세계 지식까지 학습한다는 점입니다.

모델 구조는 **Transformer 디코더**를 사용합니다.

$$h_0 = UW_e + W_p$$

$$h_l = \text{transformer_block}(h_{l-1}), \quad \forall l \in [1, n]$$

$$P(u) = \text{softmax}(h_n W_e^\top)$$

여기서 W_e 는 토큰 임베딩 행렬, W_p 는 위치 임베딩 행렬입니다. **Transformer 인코더가 아닌 디코더를 사용하는 이유**는 언어 모델이 본질적으로 왼쪽에서 오른쪽으로 다음 단어를 예측하는 단

방향(unidirectional) 태스크이기 때문입니다. 디코더의 Masked Self-Attention이 이 단방향 구조를 자연스럽게 구현합니다. (이것이 이후 BERT와의 핵심 차이점이 됩니다.)

사전 학습 모델 스펙:

- 12-layer Transformer 디코더
- 768차원 은닉 상태, 12개 Attention 헤드
- FFN 내부 차원 3,072
- BPE 어휘 40,000개
- 최대 시퀀스 길이 512 토큰
- 학습 데이터: BooksCorpus (7,000권 이상의 미출판 책, 약 8억 단어)
- 달성 perplexity: **18.4** (당시 매우 낮은 수치)

BooksCorpus를 선택한 이유가 중요합니다. 같은 크기의 1B Word Benchmark(ELMo가 사용)는 문장 단위로 섞여 있어 문장 간 장거리 문맥이 파괴됩니다. BooksCorpus는 책 단위의 긴 연속 텍스트가 보존되어 있어 장거리 의존성 학습에 훨씬 유리합니다.

3.2 Stage 2 — 지도 파인튜닝 (Supervised Fine-tuning)

사전 학습이 완료되면, 레이블 있는 데이터셋 $\mathcal{C}$ 를 이용해 파인튜닝합니다. 입력 토큰 시퀀스 $x^1, \dots, x^m$ 을 사전 학습 모델에 통과시켜 마지막 Transformer 블록의 활성화 h_l^m 을 얻고, 여기에 새로운 선형 레이어 W_y 만 추가해 레이블 y 를 예측합니다.

$$P(y \mid x^1, \dots, x^m) = \text{softmax}(h_l^m W_y)$$

$$L_2(\mathcal{C}) = \sum_{(x,y)} \log P(y \mid x^1, \dots, x^m)$$

추가로, 파인튜닝 시에도 언어 모델 목표를 보조(auxiliary) 목표로 함께 사용합니다.

$$L_3(\mathcal{C}) = L_2(\mathcal{C}) + \lambda \cdot L_1(\mathcal{C})$$

$\lambda = 0.5$ 로 설정합니다. 이 보조 목표를 추가하면 두 가지 이점이 있습니다. 지도 모델의 일반화 (generalization)가 향상되고, 학습 수렴(convergence)이 빨라집니다.

파인튜닝 시 추가되는 파라미터는 W_y 와 구분자 토큰 임베딩뿐입니다. 이것이 ELMo와의 핵심 차이점으로, ELMo는 태스크마다 별도의 모델 구조를 설계해야 했지만 GPT-1은 동일한

Transformer 위에 선형 레이어 하나만 추가하면 됩니다.

3.3 태스크별 입력 변환 (Task-specific Input Transformations)

텍스트 분류처럼 단순한 태스크는 바로 파인튜닝할 수 있지만, 두 문장의 관계를 판단하거나 문서-질문-답변 삼중쌍을 처리해야 하는 태스크는 입력 구조가 다릅니다. GPT-1은 모델 구조를 바꾸는 대신 **입력을 하나의 연속된 토큰 시퀀스로 변환**하는 방식으로 모든 태스크를 처리합니다.

텍스트 함의(Textual Entailment): 전제(premise)와 가설(hypothesis)을 구분자 토큰 \$로 이어붙여 하나의 시퀀스로 만듭니다.

$$[\text{start}] \text{ premise } [\$] \text{ hypothesis } [\text{end}]$$

유사도(Similarity): 두 문장 사이에 순서가 없으므로, 두 가지 순서(A-B, B-A)를 모두 만들어 각각 처리한 뒤 두 표현을 element-wise 합산합니다.

질문 응답 및 상식 추론(QA & Commonsense Reasoning): 문서 z , 질문 q , 각 선택지 a_k 를 다음과 같이 이어붙여 선택지 수만큼 시퀀스를 만들고 소프트맥스로 정답을 선택합니다.

$$[\text{start}] z [\$] q [\$] a_k [\text{end}]$$

이 방식의 장점은 사전 학습 모델 구조를 전혀 변경하지 않아도 된다는 것입니다. "traversal-style" 접근이라 부르며, 이 아이디어는 이후 BERT에도 그대로 이어집니다.

4. Experiment Settings

- 사전 학습 데이터: BooksCorpus (7,000권 이상, 약 8억 단어)
- 모델: 12-layer Transformer 디코더, 768차원, 12 헤드, FFN 3,072차원
- 옵티마이저: Adam (max lr = 2.5e-4), Warmup 2,000 스텝 후 코사인 감소
- 배치 크기: 64, 시퀀스 길이 512 토큰, 100 에포크
- 정규화: Residual/Embedding/Attention Dropout (0.1), L2 정규화 (w=0.01)
- 활성화 함수: GELU (ReLU 대신 사용, 더 부드러운 비선형성)
- 위치 인코딩: Sinusoidal 대신 학습된(learned) 위치 임베딩 사용
- 파인튜닝: lr 6.25e-5, 배치 32, 대부분 3 에포크로 충분

5. Results

5.1 자연어 추론 (Natural Language Inference)

5개 NLI 데이터셋 중 4개에서 새로운 SOTA를 달성했습니다. 주요 결과를 정리하면 다음과 같습니다.

태스크 이전 SOTA GPT-1 향상

MNLI-m	80.6 (양상블)	82.1	+1.5%
SciTail	83.3	88.3	+5.0%
QNLI	82.3	88.1	+5.8%
SNLI	89.3 (양상블 5개)	89.9	+0.6%
RTE	61.7	56.0	▼ (소규모 데이터셋)

RTE에서 성능이 낮은 이유는 학습 데이터가 2,490개로 매우 적기 때문입니다. 대규모 데이터셋에서는 일관되게 우수한 성능을 보입니다.

5.2 질문 응답 및 상식 추론

태스크 이전 SOTA GPT-1 향상

Story Cloze	77.6	86.5	+8.9%
RACE (전체)	53.3 (양상블 9개)	59.0	+5.7%

Story Cloze에서 8.9%라는 압도적인 향상이 인상적입니다. RACE는 중학교·고등학교 시험 문제로 구성된 데이터셋으로, 장거리 문맥 이해가 필수적입니다. Transformer의 Self-Attention이 긴 문맥을 효과적으로 처리한 덕분입니다.

5.3 의미적 유사도 및 텍스트 분류

태스크 이전 SOTA GPT-1 향상

CoLA (언어 수용성)	35.0	45.4	+10.4
SST-2 (감성 분석)	93.2	91.3	근접
STS-B (의미 유사도)	81.0	82.0	+1.0
QQP (질문 쌍)	66.1	70.3	+4.2%

GLUE 전체	68.9	72.8	+3.9
---------	------	------	------

CoLA에서 10.4점의 향상이 특히 주목할 만합니다. CoLA는 "Is this sentence grammatically acceptable?"를 판단하는 태스크로, 언어 모델 사전 학습이 문법적 지식을 얼마나 잘 내재화했는지 보여주는 지표입니다. 대규모 텍스트로 "다음 단어 예측"만 훈련했는데도 문법 판단 능력이 크게 향상된 것은 매우 흥미로운 결과입니다.

6. Analysis — 무엇이 성능을 만드는가?

6.1 전이하는 레이어 수의 영향

사전 학습 모델에서 몇 개의 레이어를 전이할수록 성능이 좋은지 분석했습니다. 결과는 명확합니다. **레이어를 많이 전이할수록 성능이 일관되게 향상됩니다.** MultiNLI에서는 임베딩만 전이할 때 대비 전체 레이어 전이 시 최대 9% 향상이 관찰됩니다. 이는 Transformer의 각 레이어가 단순히 중복된 정보를 담는 것이 아니라, **레이어마다 서로 다른 수준의 언어 지식을 인코딩함**을 시사합니다.

6.2 Zero-shot 행동 분석

파인튜닝 없이 사전 학습 모델만으로 다운스트림 태스크를 수행하면 어떤 결과가 나올까요? 각 태

스크에 대해 다음과 같은 휴리스틱을 사용했습니다.

CoLA (언어 수용성): 모델이 각 문장에 할당하는 평균 토큰 log-probability로 판단.

SST-2 (감성 분석): 문장 뒤에 "very"를 붙이고 "positive"와 "negative" 중 어느 쪽 확률이 높은지 확인.

RACE (질문 응답): 문서와 질문 조건 하에 각 선택지의 평균 token log-probability가 가장 높은 것을 정답으로 선택.

결과적으로 zero-shot 성능이 학습이 진행될수록 꾸준히 향상됩니다. 더 흥미로운 점은

Transformer가 LSTM보다 zero-shot 분산이 훨씬 낮다는 것입니다. 이는 Transformer의 귀납적 편향(inductive bias)이 언어 지식의 전이에 본질적으로 더 적합함을 의미합니다.

6.3 Ablation Study

모델 변형 평균 점수 주요 관찰

Full model (Transformer + aux LM)	74.7	기준
사전 학습 없이 직접 지도 학습	59.9	-14.8점 — 사전 학습의 절대적 중요성
보조 LM 목표 제거	75.0	근소하게 높음 (소규모 데이터에서 불필요)
Transformer → LSTM 대체	69.1	-5.6점 — Transformer 아키텍처의 우월성

가장 충격적인 결과는 **사전 학습 없이**는 평균 **14.8점이 하락**한다는 점입니다. 이는 사전 학습이 단순한 "초기값 개선" 수준이 아니라 모델 성능의 핵심 요소임을 명확히 보여줍니다. 보조 LM 목표는 대규모 데이터셋에서는 도움이 되지만 소규모에서는 효과가 미미합니다. LSTM 대체 실험은 동일한 프레임워크에서 Transformer가 LSTM보다 구조적으로 우수함을 직접 증명합니다.

7. 결론 및 의의

GPT-1은 세 가지 측면에서 NLP 역사에 큰 전환점이 됩니다.

"Pre-train then Fine-tune" 패러다임의 확립: ELMo가 "사전 학습 표현을 기존 모델에 추가"하는 방식이었다면, GPT-1은 "하나의 사전 학습 모델을 파인튜닝으로 모든 태스크에 적용"하는 패러다임을 확립합니다. 이 패러다임은 이후 BERT, GPT-2/3/4, T5 등 모든 대형 언어 모델의 기본 틀이 됩니다.

Transformer + 언어 모델링의 강력함 증명: 단순히 "다음 단어를 예측"하는 목표만으로 문법, 의미, 상식, 추론 능력까지 내재화할 수 있음을 12개 태스크에 걸쳐 실증적으로 보여줬습니다.

단방향(Unidirectional) 모델의 한계와 BERT로의 연결: GPT-1은 Transformer 디코더 기반의 단방향 언어 모델입니다. 왼쪽 문맥만 참조하므로 오른쪽 문맥을 동시에 보는 것보다 표현력이 제한됩니다. 이 한계를 Transformer 인코더 기반의 양방향 사전 학습으로 해결한 것이 바로 BERT(2018)입니다.

지금까지 리뷰한 논문들의 흐름을 정리하면 다음과 같습니다.

Seq2Seq (2014) — RNN으로 가변 길이 번역 최초 구현 → Bahdanau Attention (2015) — 고정 벡터 병목 해결 → Transformer (2017) — RNN 제거, Attention만으로 SOTA → ELMo (2018) — 사전 학습 표현의 힘 증명 (biLSTM) → GPT-1 (2018) — Transformer + Pre-train & Fine-tune 패러다임 확립 → BERT (2018) — 양방향 사전 학습으로 GPT-1의 단방향 한계 극복

2

Tag

fine-tuning

gpt-1

LLM

NLP

Transformer

'카테고리 없음'의 다른글

이전글 [Paper Review] Attention Is All You Need (Transformer)

현재글 : [Paper Review] Improving Language Understanding by Generative Pre-Training (GPT-1)

다음글 [Paper Review] BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding

autumnqp 님의 블로그

autumnqp 님의 블로그 입니다.

댓글 1



박현숙43

안녕하세요 🍁

당신의 글을 읽는 것은 정말 큰 기쁨이었습니다.

당신의 글에는 잔잔한 진솔함과 신선함이 담겨 있어 마음을 편안하게 하면서도 영감을 줍니다.

앞으로도 당신의 사려 깊은 글들을 더 많이 공유해 주시기를 진심으로 바랍니다. 그들은 정말 오래도록 기억에 남는 인상을 남깁니다.

오늘 하루도 은혜와 행복, 그리고 아름다운 순간들로 가득하시길 바랍니다.^^

2026. 5. 6. 22:08 답글



autumnqp

등록



autumnqp 님의 블로그

autumnqp 님의 블로그 입니다.

글쓰기

블로그 관리

분류 전체보기 (6) 

Paper review (0)

Tag

gpt-1, DNNs, fine-tuning, RNN,
encoder-decoder, Bleu, Transformer, elmo,
biLM, LSTM,
Deep contextualized word representations, NMT,
CoVe, LLM, Attention, NLP, BERT, Seq2Seq,
Convolutional Neural Networks, CLS

최근글 인기글

[Paper Review] BERT: Pre-training of Deep
Bidirectional Transformers...

2026.05.06 22:36

[Paper Review] Improving
Language Understanding by
Generative Pre-Tr...

2026.05.06 21:45

[Paper Review] Attention Is All You
Need (Transformer)

2026.05.06 20:03

최근댓글

공지사항

Facebook Twitter

Archives

2026/05

2026/04

〈 2026. 05 〉


일	월	화	수	목	금	토
					1	2
3	4	5	<u>6</u>	7	8	9
10	11	12	13	14	15	16
17	18	19	20	21	22	23
24	25	26	27	28	29	30
31						

Total

4

Today : 1
Yesterday : 2

검색내용을 입력하세요.



Copyright © AXZ Corp. All rights reserved.

관련사이트